

Análisis de Datos Científicos: Series temporales en registros de EEG

Betina González

Resumen

Se realizaron registros de EEG multicanal para la adquisición de datos en tiempo real, mientras el sujeto completaba cinco tareas paradigmáticas para evocar componentes cognitivos y afectivos de referencia: P300 y FRN (error de predicción y mismatch visual), N400 semántica (violación de expectativa lingüística), LPP (estímulos afectivos) y la N400 matemática (detección de inconsistencias aritméticas).

Introducción

La electroencefalografía (EEG) es una técnica neurofisiológica no invasiva que mide la actividad eléctrica global del cerebro. Esta señal se origina a partir de fluctuaciones de voltaje generadas por la suma sincrónica de los potenciales postsinápticos en las neuronas piramidales de la corteza cerebral, que se registran mediante electrodos colocados sobre el cuero cabelludo. A diferencia de las técnicas de neuroimaging estructural, el EEG se utiliza por su resolución temporal en milisegundos, lo que permite capturar dinámicas cerebrales en tiempo real, y estudiar los *Potenciales Evocados Relacionados a Eventos* (ERP). Los ERPs son deflexiones de voltaje específicas en el tiempo y el espacio que reflejan fases discretas del procesamiento de la información. En este trabajo, la utilización de un sistema EEG multicanal permitió decodificar respuestas cognitivas automatizadas frente al error o la sorpresa establecidas, como los componentes N400¹ (negativa con pico a 400 ms), FRN² (*feedback related negativity*, con pico a 200-300 ms) y P300² (positiva con pico a 300 ms), o la intensidad la carga afectiva visual, como el componente LPP³ (positiva con pico a 600 ms). El análisis demuestra la viabilidad de aislar firmas electrofisiológicas sutiles asociadas al lenguaje, la lógica y la emoción mediante registros dinámicos de corta duración.

Materiales y Métodos

1. Sujeto y Configuración Experimental

Las mediciones se realizaron sobre un único sujeto experimental voluntario, que ejecutó secuencialmente cinco tareas paradigmáticas desarrolladas en Pygame. Durante las sesiones, el sujeto interactuó con los estímulos visuales seleccionando opciones binarias (Izquierda/Derecha) con el teclado. El software gestionó los bloques, la aleatorización de los estímulos y el registro inmediato de las respuestas comportamentales de forma sincrónica con la señal bioeléctrica. La Tabla 1 muestra un resumen metodológico de los paradigmas experimentales ejecutados:

Tabla 1: Descripción de la tarea, distribución de clases (N épocas limpias tras limpieza de artefactos), ventanas temporales de extracción de características y canales de registro seleccionados.

Paradigma	Descripción	Distribución de Clases	Componente	Ventana (ms)	Canal Analizado
Ecuaciones matemáticas.	Se propone una cuenta y luego se muestra el resultado	Correctas: 18 Incorrectas: 15	N400 Aritmética	250 - 450	CH_1 (Frontal)
Congruencia lingüística en oraciones	Seleccionar si una frase tiene o no sentido	Normales: 11 Absurdas: 11	N400 Semántica	350 - 550	CH_1 (Frontal)
Procesamiento emocional	Sucesión de imágenes afectivas felices y tristes vs neutras	Neutras: 13 Emocionales: 24	LPP Emocional	350 - 700	CH_7 (Posterior)
Aprendizaje por refuerzo y feedback	Predicción de caja ganadora (con probabilidades 80-20)	Ganancias: 63 Pérdidas: 9	FRN y P300	200 - 500	CH_1 (Frontal)
Oddball visual de control vs sorpresa	Sucesión de imágenes esperadas vs discordantes	Estándar: 48 Desviado: 12	P300 Mismatch	300 - 600	CH_7 (Posterior)

2. Adquisición y Sincronización de la Señal EEG

El registro multicanal se llevó a cabo utilizando un sistema de adquisición de grado de investigación g.tec, conectado a un casco de electrodos posicionado según el sistema internacional 10-20. La captura y el streaming inicial de las señales bioeléctricas desde el hardware hacia la estación de trabajo se gestionaron a través del software g.NEEDaccess. La sincronización temporal precisa y la unificación de los datos se realizó mediante el protocolo Lab Streaming Layer (LSL). Cada vez

que el script de Pygame detectaba una entrada válida del sujeto o presentaba un estímulo crítico en pantalla, enviaba un marcador numérico (trigger) a través de un outlet de LSL. Todas las marcas de tiempo del archivo log se acoplaron al reloj absoluto del EEG utilizando la ecuación de sincronización lineal basada en el vector de tiempo transcurrido del experimento: $LSL_{evento} = LSL_{inicio_eeg} + t_{experimento}$. La frecuencia de muestreo para todos los registros fue de 250 Hz. Para el procesamiento de las tareas asociadas a mecanismos prefrontales, procesamiento del conflicto, lenguaje y error lógico, se seleccionó el canal frontal CH_1. Para las tareas asociadas a la atención sostenida, procesamiento visual complejo y valencia afectiva, se analizó el canal parietal/occipital posterior CH_7.

3. Pipeline de Preprocesamiento Digital

El flujo de tratamiento digital de la señal constó de los siguientes pasos secuenciales:

Filtrado Temporal: Se aplicó un filtro digital Butterworth pasa-banda de orden 4, con frecuencias de corte de 1.0 Hz y 20.0 Hz, para remover fluctuaciones lentas de línea de base y reducir componentes de alta frecuencia asociadas a ruido muscular y artefactos no neuronales.

Sincronización y Segmentación (epocado): La ventana de epocado se definió desde -200 ms hasta 800 ms respecto al tiempo cero 0 ms, definido por la aparición del estímulo en pantalla.

Corrección de Línea de Base Local: Para cada época extraída de forma individual, se calculó el voltaje promedio del intervalo pre-estímulo (ventana de -200 ms a 0 ms, equivalente a las primeras 50 muestras). Este valor medio se restó localmente a todo el fragmento.

Limpieza de Artefactos: Se fijó un umbral de tolerancia de 35 μV , estimado a partir del registro de *blinking* del sujeto. Los fragmentos que superaron dicho límite fueron automáticamente descartados previo al promediado y modelado.

4. Extracción de *features*, clasificación supervisada y evaluación estadística

De cada época limpia, se extrajeron como features todos los puntos temporales de la señal dentro de la ventana de interés correspondiente al componente ERP analizado, preservando así la morfología temporal completa de cada ensayo individual. La evaluación de los modelos se realizó mediante validación cruzada estratificada de 5 folds (Stratified K-Fold), permitiendo utilizar la totalidad del dataset y mantener la proporción original de clases en cada partición. Se implementaron dos familias de clasificadores supervisados utilizando Scikit-Learn:

Support Vector Machine (SVM): configurado con `kernel='linear'`, penalización `C=1.0`, compensación automática de desbalance de clases (`class_weight='balanced'`) y `random_state=42`. Previamente, las features fueron normalizadas mediante transformación z-score utilizando `StandardScaler`.

Random Forest: configurado con `n_estimators=60`, `max_depth=3`, `class_weight='balanced'` y `random_state=42`.

Resultados

Ecuaciones matemáticas: N400 aritmética

El análisis del ERP en esta tarea revela un comportamiento esperado en la ventana N400 matemática: las ecuaciones *incorrectas* provocan una deflexión negativa más profunda en comparación con las *correctas*, como resultado de la detección del conflicto lógico (Fig.1). Sin embargo, a nivel clasificador, la bajísima cantidad de ensayos de validación ($n=7$) impide la generalización, evidenciando que el promedio estabiliza el ERP pero los clasificadores fallan por falta de datos.




Figura 1. Izq: Valores medios de ERP tomados en CH_1. Der: matrices de confusión de los modelos supervisados.

Congruencia lingüística en oraciones: N400 semántica

El análisis del ERP para este paradigma no exhibió la dinámica esperada: en la ventana sombreada, la *Condición Absurda* presenta una polaridad marcadamente más positiva que la *Condición Normal*, invirtiendo el efecto N400 clásico (Fig.2). Las matrices de confusión no evidenciaron un sesgo sistemático hacia una única clase. Tanto el modelo SVM como Random Forest mostraron una capacidad de clasificación moderada y relativamente balanceada entre frases normales y absurdas.




Figura 2. Izq: Valores medios de ERP tomados en CH_1. Der: matrices de confusión de los modelos supervisados.

Procesamiento emocional: LPP

El análisis morfológico del ERP exhibe un comportamiento compatible con el componente LPP (350-700 ms): la curva de *Contenido Emocional* mantiene una tendencia tónica superior y más positiva en comparación con las *Imágenes Neutras*, reflejando el enganche atencional afectivo (Fig.3). A nivel de clasificación, ambos modelos mostraron un rendimiento limitado, aunque con diferencias relevantes en sensibilidad hacia el contenido emocional: la SVM presentó un desempeño cercano al azar, con una leve tendencia a favorecer la clase "Emocional", pero sin lograr una separación robusta entre condiciones, mientras que Random Forest alcanzó un rendimiento superior (balanced accuracy = 0.571), mostrando una mayor capacidad para detectar estímulos emocionales (recall = 0.83) a costa de una sensibilidad reducida para las imágenes neutras.




Figura 3. Izq: Valores medios de ERP tomados en CH_7. Der: matrices de confusión de los modelos supervisados.

Aprendizaje por refuerzo y feedback: FRN y P300

El ERP en este paradigma muestra un claro comportamiento divergente ante el error de predicción: la *pérdida inesperada* genera una deflexión negativa prominente en la ventana de la FRN, seguida de un valle que se extiende en la fase de la P300, con una recuperación de la curva a partir de 400 ms que parece ser el efecto positivo de la P300 sumándose a la abrupta caída de voltaje inducida por la FRN (Fig.4). A pesar del claro perfil electrofisiológico, los clasificadores fallaron en aprender la clase minoritaria de *pérdida inesperada*, algo totalmente esperable dado la baja cantidad de casos en el dataset (9 en total). Si tenemos esto en cuenta, la SVM preformó mejor que el random forest al poder asignar correctamente un caso *pérdida*.




Figura 4. Izq: Valores medios de ERP tomados en CH_1. Der: matrices de confusión de los modelos supervisados.

Oddball visual de control vs sorpresa (mismatch): P300

El análisis del ERP para este paradigma no exhibió la dinámica esperada: la condición *Estándar* permanece atenuada, mientras que el estímulo *Desviado* debería evocar un componente P300 dentro de la ventana de interés, que no se observa en el gráfico (Fig.5). Además, el registro de la condición Desviado presenta mucha fluctuación. Los modelos mostraron un rendimiento moderado pero limitado para discriminar entre estímulos estándar y desviados. La SVM presentó una mayor sensibilidad hacia la clase *Desviado* (recall = 0.58), aunque a costa de una elevada tasa de falsos positivos sobre la clase estándar. En contraste, el Random Forest favoreció claramente la clase mayoritaria *Estándar*, alcanzando alta precisión global (accuracy = 0.76) pero con muy baja detección de estímulos desviados (recall = 0.17). Las balanced accuracy obtenidas indican que ninguno de los modelos logró una separación robusta y equilibrada entre ambas condiciones.




Figura 5. Izq: Valores medios de ERP tomados en CH_7. Der: matrices de confusión de los modelos supervisados.

Conclusiones

A nivel electrofisiológico, el promediado sincrónico de las señales logró aislar con éxito algunas firmas neurofisiológicas de referencia esperadas en la literatura: se evidenció la modulación de la FRN/P300 ante el error de predicción, el desplome de la N400 matemática frente al conflicto lógico, la respuesta atencional del componente LPP ante estímulos afectivos. Sin embargo, se halló una marcada divergencia en la aplicación de modelos predictivos. Tanto los modelos lineales (SVM) como los de ensamble (Random Forest) exhibieron severas limitaciones para generalizar las fronteras de decisión. Esta degradación predictiva no responde a una falla del diseño experimental, sino a factores metodológicos críticos: la baja relación señal-ruido intrínseca de las épocas individuales sin promediar y, fundamentalmente, el drástico desbalance de clases y reducido tamaño muestral. Además, el sujeto de experimentación conocía las tareas, fue el desarrollador de las rutinas en pygame, por lo que la saliencia de los estímulos puede haberse visto comprometida. Para futuros desarrollos, se vuelve indispensable expandir el volumen de sujetos y ensayos, y contemplar la implementación de técnicas de balanceo sintético de datos.

Bibliografía

- 1 Kutas M, Federmeier KD. Thirty years and counting: finding meaning in the N400 component of the event-related brain potential (ERP). *Annu Rev Psychol.* 2011; 62:621-47.
- 2 Mushtaq F, et al. Distinct Neural Signatures of Outcome Monitoring After Selection and Execution Errors. *J Cogn Neurosci.* 2022; 34(5):748-765.
- 3 Brown SB, et al. Functional significance of the emotion-related late positive potential. *Front Hum Neurosci.* 2012; 6:33.